
UNIVERSIDADE FEDERAL DE OURO PRETO
DEPARTAMENTO DE CIÊNCIA DE COMPUTAÇÃO
PROCESSAMENTO DIGITAL DE IMAGENS

Projeto de Pesquisa

SEGMENTAÇÃO DE LESÕES NA PELE

Alunos:

Marcos Geraldo Braga Emiliano,

,

Resumo

Quando tratamos do atendimento do paciente a entrevista do mesmo ainda existem muitos pontos a serem definidos para automatizar tais processos, porem para a análise de exames, fotografias, dados definidos sobre um paciente tal etapa do processo pode sofrer algum nível de automatização devido a característica dos dados, pois tornaria o processo mais rápido, ou ate mesmo poderia diminuir a ocorrência de erros.

Lesões na pele são diagnosticadas, de forma inicial, por meio de uma inspeção visual da lesão, sendo assim, por meio de uma foto é possível determinar a chance daquela lesão ser uma condição preocupante ou não, sendo assim, se torna possível utilizar das imagens de lesões para automatizar, ao menos, essa fase de diagnostico inicial da lesão.

Sendo assim seria viável se utilizar de uma rede neural para realizar a segmentação das imagens dermatológicas de lesões.

Onde, por meio do modelo proposto foi possível gerar as mascaras necessárias para segmentar imagens dermatológicas de manchas na pele, auxiliando em demais analises que fossem realizadas posteriormente na imagem.

1 Introdução

A tele medicina foi um tema muito aquecido durante o período de distanciamento social que ocorreu recentemente na pandemia de Covid-19, pois pequenas enfermidades eram desencorajadas a irem em um hospital ou posto de saúde, desta forma se viu a possibilidade de um acompanhamento remoto destas pessoas, porem de forma geral a medicina ainda é uma área com muito pouca automatização, onde ainda é necessário o acompanhamento do medico para uma serie de analises e verificações, o que se torna um processo custoso quando avaliamos o macro da situação.

Quando tratamos do atendimento do paciente a entrevista do mesmo ainda existem muitos pontos a serem definidos para automatizar tais processos, porem para a análise de exames, fotografias, dados definidos sobre um paciente tal etapa do processo pode sofrer algum nível de automatização devido a característica dos dados, pois tornaria o processo mais rápido, ou ate mesmo poderia diminuir a ocorrência de erros.

Lesões na pele são diagnosticadas, de forma inicial, por meio de uma inspeção visual da lesão, sendo assim, por meio de uma foto é possível determinar a chance daquela lesão ser uma condição preocupante ou não, sendo assim, se torna possível utilizar das imagens de lesões para automatizar, ao menos, essa fase de diagnostico inicial da lesão.

E atualmente para o reconhecimento de imagens se utiliza com grande frequência CNNs, que tem um alto custo computacional porem produzem bons resultados para tal, e um dos fatores que aumenta o acurácia de tais redes é a remoção das informações que não agregam valor a informação da lesão, como pelos, elevações, possíveis marcas não relacionadas com a lesão, uma serie de fatores, e para mitigar tal efeito é interessante se realizar uma mascara na imagem se obstruindo as informações que não nos interessam. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc

quis urna dictum turpis accumsan semper.

2 Estado da Arte

Tendo em vista como é uma escolha complexa definir qual arquitetura será usada para realizar uma segmentação ou uma classificação em uma imagem que possui uma lesão de pele, é de grande valor analisar e buscar resultados já obtidos anteriormente em outros trabalhos, desta forma foi avaliado valido se analisar e incluir informações dos trabalhos citados a seguir.

O trabalho *Rethinking Skin Lesion Segmentation in a Convolutional Classifier* [Burdick \(2018\)](#) busca de forma empírica demonstrar que segmentar uma lesão de pele, borrando o que se encontra ao redor da lesão alvo, removendo, marcas na pele, pelos, cicatrizes, a própria textura da pele, informações que não nos interessam quando se trata de identificar uma lesão na pele, aumenta a acurácia de classificação em CNNs. Para demonstrar a máscara de segmentação foi cada vez mais dilatada tendo como base mascaras geradas manualmente. O trabalho chegou ao resultado de que segmentar a lesão melhora todos os parâmetros avaliados, acurácia, precisão, sensibilidade e AUC (*Area Under the Curve*), sendo assim, qualquer nível de segmentação, condizente com os avaliados nesse trabalho, obtiveram resultados melhores do que nenhuma segmentação. Como critica a este trabalho, poderiam ser utilizados outros métodos para minimizar os ruídos presentes nas imagens buscando melhorar o foco da rede neural.

O paper *Dense Deconvolutional Network for Skin Lesion Segmentation* [Li et al. \(2019\)](#) propõe uma DDN, *dense deconvolutional network*, para gerar o *ground true* de lesões na pele de forma automática, buscando facilitar a análise e verificação de tais dados. Os resultados obtidos em alguns casos foram promissores comparados com outras formas automáticas de segmentação de dados, obtendo-se resultados relevantes. Como a rede proposta não foi tida como eficiente em todos os casos ainda existe espaço para melhoria.

O *Skin Lesion Segmentation with Improved Convolutional Neural Network* [Oztürk S \(2020\)](#) propõe uma nova arquitetura de uma FCN, *fully convolutional network*, buscando aumentar a acurácia da análise automática das imagens. O trabalho cita que para aumentar a acurácia são utilizados severos métodos de tratamento de dados, para remover pelos e outros fatores externos, o que acaba aumentando a carga de processamento, pois existem vários métodos distintos utilizados para

isso, porem eles querem propor uma arquitetura que não dependa destes métodos para trabalhar de forma acurada. Os resultados foram promissores, a rede proposta alcançou valores expressivos comparado com outras soluções existentes, devido a seu foco único em lesões de pele.

A publicação *Skin Lesion Segmentation in Clinical Images Using Deep Learning* Jafari et al. (2016) tem alguns pontos interessantes a serem avaliados, a imagem é trabalhada em várias fases, passando por um pré-processamento, uma partição de partes locais e globais, o que será falado em detalhes mais tarde, a passagem pela CNN e o pós processamento, onde cada passo desse tem uma importância significativa no resultado, mas o mais interessante é a partição feita na imagem, onde é recortado da imagem grandes quantidades de informações a serem usadas no treinamento e também pequenas seções da imagens buscando avaliar detalhes da imagem, sendo assim possível adicionar no *ground true* também as pequenas curvas presentes na lesão. Os resultados obtidos foram muito significativos, onde foi obtido uma grande acurácia comparado com outro método, desta forma foi possível identificar de maneira coesa a área da lesão.

E *Skin Lesion Segmentation: U-Nets versus Clustering* Lin et al. (2017), tal trabalho compara duas formas de segmentar uma lesão na pele, o primeiro usando U-nets com um pré-processamento se utilizando de equalização de histograma e o segundo é um método de agrupamento *C-Means* que é mais leve de executar e simples de implementar, tendo em vista que grandes redes neurais demandam de grande volume de GPU e se utilizando o *clustering* podemos realizar em CPU os cálculos de forma eficiente. Como resultado esse trabalho demonstrou um método relativamente eficiente para se realizar a segmentação de lesões na pele, se utilizando de métodos não dependentes de GPU, sendo assim possível, de forma razoável, se realizar a segmentação destas lesões em contextos onde não se tem disponibilidade de uma GPU.

3 Metodologia

Foi utilizada um modelo de segmentação baseado em uma *SegNet*, que é uma arquitetura de rede convolucional profunda para segmentação semântica. A principal motivação por trás do *SegNet* foi a necessidade de se escolher uma arquitetura eficiente para a compreensão da estrada e da cena interna que fosse eficiente tanto em termos de memória quanto de tempo computacional. Onde a *SegNet*, é mais eficiente, pois armazena apenas os índices *max-pooling* dos mapas de re-

curso e os utiliza em sua rede de decodificadores para obter um bom desempenho. O modelo foi treinado usando a base de dados PH2 3.1.

3.1 Base de Dados

A crescente incidência de melanoma tem promovido recentemente o desenvolvimento de sistemas de diagnóstico auxiliado por computador para a classificação de imagens dermatoscópicas. O conjunto de dados PH2 ADDI (2011) foi desenvolvido para fins de pesquisa e *benchmarking*, a fim de facilitar estudos comparativos sobre algoritmos de segmentação e classificação de imagens dermatoscópicas. PH2 é uma base de dados de imagens dermatoscópicas adquiridas no Serviço de Dermatologia do Hospital Pedro Hispano, Matosinhos, Portugal.

Este banco de imagens contém um total de 200 imagens dermatoscópicas de lesões melanocíticas, incluindo 80 manchas comuns, 80 manchas atípicas e 40 melanomas. A base de dados PH2 inclui anotação médica de todas as imagens nomeadamente segmentação médica da lesão, diagnóstico clínico e histológico e avaliação de vários critérios dermatoscópicos (cores; rede pigmentar; pontos/glóbulos; estrias; áreas de regressão; véu azul-esbranquiçado).

Figura 1: Atributos

| Criterion | PH ² Segmentation |
|----------------------------|---|
| Clinical Diagnosis | 0 - Common Nevus |
| | 1 - Atypical Nevus |
| | 2 - Melanoma |
| Lesion Segmentation | Available as a binary mask (with the same size of the original image). |
| Color Segmentation | Available as a binary mask (with the same size of the original image) (If available). |
| Asymmetry | 0 - Fully Symmetry |
| | 1 - Asymmetry in One Axis |
| | 2 - Fully Asymmetry |
| Pigment Network | AT - Atypical |
| | T - Typical |
| Dots/Globules | A - Absent |
| | AT - Atypical |
| | T - Typical |
| Streaks | A - Absent |
| | P - Present |
| Regression Areas | A - Absent |
| | P - Present |
| Blue Whitish Veil | A - Absent |
| | P - Present |
| Colors | 1 - White |
| | 2 - Red |
| | 3 - Light-Brown |
| | 4 - Dark-Brown |
| | 5 - Blue-Gray |
| | 6 - Black |

3.2 Modelo de Segmentação

O modelo foi baseado em um previamente implementado e disponibilidade por um usuário do *kaggle* [HANSERN \(2021\)](#). Os procedimentos que foram aplicados do tratamento dos dados até a

inferência estão descritos em detalhes a seguir

3.2.1 Tratamentos dos Dados

A resolução das imagens foi alterada, ela foi diminuída de (572, 765) para (192,256), o tamanho das imagens influencia de forma considerável o tempo demandado para treinar a rede.

As imagens já transformadas são colocadas em vetores *numpy*, visando uma maior facilidade de manipulação e utilização. Após essas alterações os dados são separados em treino e teste, visando avaliar o resultado do treino do modelo.

3.2.2 Aumento de Dados

Foi realizado também um aumento de dados visando se tornar o conjunto de dados mais diverso aumentando a capacidade de generalização do modelo, os métodos aplicados foram o espelhamento horizontal, o espelhamento vertical, ambos espelhamentos e uma rotação aleatória, onde tais dados são adicionados aos dados de treinamento.

3.2.3 Métricas de Avaliação

Intersection over Union(IOUS) ou *Jaccard Index* o índice de Jaccard, também conhecido como intercessão sobre a união é o coeficiente de similaridade de Jaccard, é uma estatística usada para medir a similaridade e diversidade de conjuntos de amostras. O coeficiente de Jaccard mede a similaridade entre conjuntos de amostras finitas e é definido como o tamanho da interseção dividido pelo tamanho da união dos conjuntos de amostras. O índice Jaccard é popular e frequentemente usado como índice de similaridade. A área de sobreposição J é calculada entre a imagem binária segmentada A e sua verdade fundamental G como mostrado:

$$J = |A \cap G| / |A \cup G| \times 100\% \quad (1)$$

O *Dice Coefficient* não é apenas uma medida de quantos positivos você encontra, mas também penaliza os falsos positivos que o método encontra, semelhante à precisão. por isso é mais

semelhante à precisão do que à exatidão. O coeficiente *Dice* pode ser definido como:

$$D = 2 |A \cup G| / |A + G| \times 100\% \quad (2)$$

onde A é a saída do algoritmo e G é a verdade absoluta.

A precisão é uma boa medida para determinar, quando os custos do Falso Positivo são altos. $\text{Precisão} = \text{verdadeiro positivo} / (\text{verdadeiro positivo} + \text{falso positivo})$ Onde, Verdadeiro positivo é um resultado em que o modelo prevê corretamente a classe positiva e falso positivo é um resultado em que o modelo prevê incorretamente a classe positiva. "Precisão calcula uma métrica para classificação multi-rótulo de quantos itens selecionados são relevantes."

O *Recall* calcula quantos dos Positivos Reais nosso modelo captura ao rotulá-lo como Positivo (Verdadeiro Positivo). Aplicando o mesmo entendimento, sabemos que *Recall* será a métrica do modelo que usamos para selecionar nosso melhor modelo quando há um alto custo associado a Falso Negativo.

$$\text{Recall} = \text{verdadeiro positivo} / (\text{verdadeiro positivo} + \text{falso negativo})$$

Onde, verdadeiro positivo é um resultado em que o modelo prevê corretamente a classe positiva e falso negativo é um resultado em que o modelo prevê incorretamente a classe negativa. "*Recall* calcula uma métrica para classificação multi-rótulo de quantos itens relevantes são selecionados."

Acurácia "Calcula a taxa de precisão média em todas as previsões para problemas de classificação binária."

3.2.4 O Modelo

Foi adotado o algoritmo de otimização adam ou momentos adaptativos, para ajustar a taxa de aprendizado É conhecido que a taxa de aprendizado é um dos hiperparâmetros críticos que têm um impacto significativo no desempenho da classificação.

SegNet, uma arquitetura de rede convolucional profunda para segmentação semântica. A principal motivação por trás do *SegNet* foi a necessidade de projetar uma arquitetura eficiente para a compreensão da estrada e da cena interna que fosse eficiente tanto em termos de memória quanto de tempo computacional.

A rede possui a seguinte disposição:

- Camadas de *Encoding*:
- Conv2D(64, (3, 3), padding='same',strides= (1,1))
- BatchNormalization(x)
- Activation('relu')(x)
- Conv2D(64, (3, 3), padding='same')(x)
- BatchNormalization(x)
- Activation('relu')(x)
- MaxPooling2D()(x)
- Conv2D(64, (3, 3), padding='same',strides= (1,1))
- BatchNormalization(x)
- Activation('relu')(x)
- Conv2D(64, (3, 3), padding='same')(x)
- BatchNormalization(x)
- Activation('relu')(x)
- MaxPooling2D()(x)
- Dense(256, activation = 'relu')(x)
- Dense(256, activation = 'relu')(x)
- Camadas de *Decoding*:
- UpSampling2D()(x)
- Conv2DTranspose(128, (3, 3), padding='same')(x)
- BatchNormalization(x)

- `Activation('relu')(x)`
- `Conv2DTranspose(64, (3, 3), padding='same')(x)`
- `BatchNormalization(x)`
- `Activation('relu')(x)`
- `UpSampling2D()(x)`
- `Conv2DTranspose(128, (3, 3), padding='same')(x)`
- `BatchNormalization(x)`
- `Activation('relu')(x)`
- `Conv2DTranspose(64, (3, 3), padding='same')(x)`
- `BatchNormalization(x)`
- `Activation('relu')(x)`

3.2.5 Aprimoramento final

As saídas previstas, originalmente, estão embaçadas porque os valores de pixel previstos estão no intervalo de 0 a 1. Para fazer previsões claras de borda, podemos aprimorar nossa imagem arredondando os valores de pixel para 1 que são $> 0,5$. Ao arredondar para baixo os valores de pixel para 0 que são $< 0,5$. Pode ser aprimorada a imagem para procurar a forma absoluta prevista pelo teto e piso dos valores previstos.

4 Resultados

Os resultados foram obtidos por meio do modelo sendo treinado localmente com a estrutura anteriormente citada. Os resultados das métricas foram: Durante o treino

- IOU: 87.77
- Dice Coef: 69.43

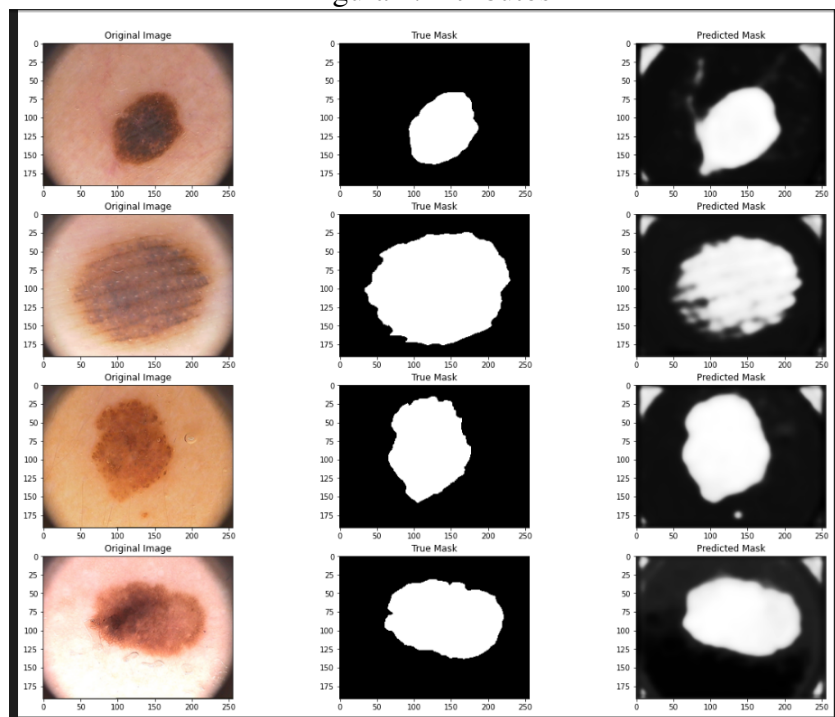
- Precision: 86.91
- Recall: 77.42
- Accuracy: 89.16
- Loss: 31.38

Durante a Validação:

- IOU: 26.03
- Dice Coef: 146.97
- Precision: 102.70
- Recall: 100.00
- Accuracy: 73.24
- Loss: -19065.87
- Recall: 78.08
- Accuracy: 88.42
- Loss: 32.40

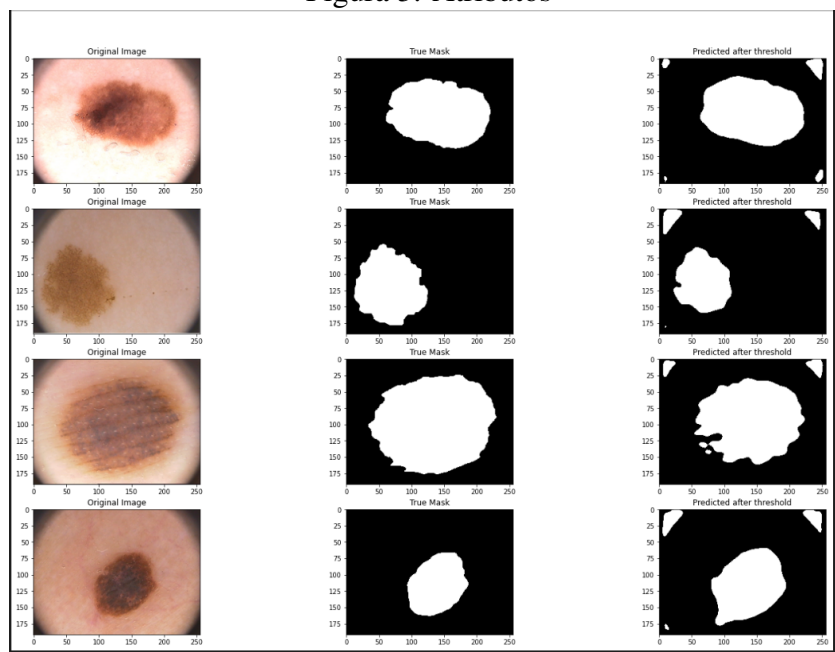
Mascaras geradas:

Figura 2: Atributos



Mascaras apos tratamento:

Figura 3: Atributos



4.1 Conclusão

Por meio do modelo proposto foi possível gerar as mascaras necessárias para segmentar imagens dermatológicas de manchas na pele, auxiliando em demais análises que fossem realizadas posteriormente na imagem.

Referências

- ADDI. (2011). Ph2 database.. doi: <https://www.fc.up.pt/addi/ph2\%20database.html>
- Burdick, M. O. W., J. (2018). Rethinking skin lesion segmentation in a convolutional classifier.. doi: doi.org/10.1007/s10278-017-0026-y
- HANSERN. (2021). Skin cancer segmentation.. doi: <https://www.kaggle.com/code/hansern/skin-cancer-segmentation/notebook>
- Jafari, M., Karimi, N., Nasr-Esfahani, E., Samavi, S., Soroushmehr, S., Ward, K., & Najarian, K. (2016). Skin lesion segmentation in clinical images using deep learning. In *2016 23rd international conference on pattern recognition (icpr)* (p. 337-342). doi: 10.1109/ICPR.2016.7899656
- Li, H., He, X., Zhou, F., Yu, Z., Ni, D., Chen, S., ... Lei, B. (2019). Dense deconvolutional network for skin lesion segmentation. *IEEE Journal of Biomedical and Health Informatics*, 23(2), 527-537. doi: 10.1109/JBHI.2018.2859898
- Lin, B. S., Michael, K., Kalra, S., & Tizhoosh, H. (2017). Skin lesion segmentation: U-nets versus clustering. In *2017 IEEE Symposium Series on Computational Intelligence (SSCI)* (p. 1-7). doi: 10.1109/SSCI.2017.8280804
- Ozturk S, O. U. (2020). Skin lesion segmentation with improved convolutional neural network.. doi: 10.1007/s10278-020-00343-z4